

## Cálculo Numérico - Método dos Mínimos Quadrados: introdução e ajuste linear

Prof<sup>a</sup>. Vanessa Rolnik - DCM - FFCLRP/USP

Este material é baseado nas Seções 7.1 e 7.2 do livro FRANCO, N.B. Cálculo Numérico. São Paulo: Pearson Prentice Hall, 2006.

### Introdução

Ajustar uma curva consiste em escolher uma família de funções  $g$  que depende de alguns parâmetros e determinar tais parâmetros de forma que melhor represente os dados disponíveis. Por exemplo,

$$g(x) = a_1g_1(x) + a_2g_2(x) + \cdots + a_mg_m(x),$$


em que a família de funções  $\{g_1, g_2, \dots, g_m\}$  são escolhidas e os parâmetros a determinar são  $a_1, a_2, \dots, a_m$ .

Quanto aos dados a serem ajustados, podem ter

- uma função  $f$  que possui algum inconveniente como ter a expressão complicada, não ser derivável, o gráfico com muitas oscilações, etc..., e precisamos de algo mais conveniente e que ao mesmo tempo não perca certas características da  $f$ , como periodicidade, crescimento, oscilações, etc. (**caso contínuo**)
- um conjunto de pontos  $(x_i, f(x_i))$  e precisamos de uma função contínua que represente os dados (**caso discreto**)

O ajuste de curvas pelo Método dos Mínimos Quadrados fornece uma “boa aproximação” para a  $f$  e permite “extrapolar” as informações/tendências com uma certa margem de segurança.

Exemplo: Em uma experiência foram medidos vários valores de corrente elétrica que passa por uma resistência submetida a várias tensões, conforme figura



Sabendo que  $V = Ri$ , queremos determinar o  $R$  que faz a reta melhor se ajustar aos pontos.

## Ajuste linear - caso discreto

$f$  tabelada e  $g$  é um polinômio do 1º grau

$x$	$x_1$	$x_2$	$\cdots$	$x_n$
$f(x)$	$f(x_1)$	$f(x_2)$	$\cdots$	$f(x_n)$

$$f(x) \approx g(x) = a + bx$$

queremos determinar os parâmetros  $a$  e  $b$  de modo que a função  $g$  esteja mais próxima possível da  $f$  em algum sentido.

Precisamos definir uma forma de medir o erro entre  $f$  e  $g$ . Seja a função resíduo

$$r(x) = f(x) - g(x)$$

- 1a. ideia:  $\sum_{i=1}^n r(x_i)$ , não é interessante pois os erros positivos e negativos se cancelam;
- 2a. ideia:  $\sum_{i=1}^n |r(x_i)|$ , não é interessante pois a função módulo não é derivável em todos os pontos
- 3a. ideia:  $\sum_{i=1}^n (r(x_i))^2$  esta sim é interessante! Não cancela erros positivos e negativos, a função  $x^2$  é derivável em toda a reta e, além disso, penaliza os erros grandes e bonifica erros pequenos.

Mais especificamente, queremos determinar os parâmetros  $a$  e  $b$  de modo que a reta  $g$  minimize a soma dos resíduos ao quadrado. Daí o nome Método dos Mínimos Quadrados.

Para isso, vamos declarar a função  $M(a, b) = \sum_{i=1}^n (r(x_i))^2 = \sum_{i=1}^n [f(x_i) - a - bx_i]^2$ , derivar e igualar a zero

$$\begin{aligned}\frac{\partial M}{\partial a} &= 2 \sum_{i=1}^n [f(x_i) - a - bx_i](-1) = 0 \\ \frac{\partial M}{\partial b} &= 2 \sum_{i=1}^n [f(x_i) - a - bx_i](-x_i) = 0\end{aligned}$$

Reorganizando as equações, obtemos um sistema linear de 2 equações e 2 incógnitas,  $a$  e  $b$ , chamado **sistema normal**

$$\begin{cases} \left( \sum_{i=1}^n 1 \right) a + \left( \sum_{i=1}^n x_i \right) b = \sum_{i=1}^n f(x_i) \\ \left( \sum_{i=1}^n x_i \right) a + \left( \sum_{i=1}^n x_i^2 \right) b = \sum_{i=1}^n x_i f(x_i) \end{cases} \quad (1)$$

É possível verificar que o sistema normal possui solução única desde que todos os  $x_i$ 's sejam distintos e que a solução,  $(a^*, b^*)$ , é um ponto de mínimo de  $M$ .

Assim, podemos concluir que entre os conjuntos de todos os polinômios do 1º grau, o que melhor se ajusta aos dados, no sentido dos mínimos quadrados, é  $g(x) = a^* + b^*x$ . Qualquer outro possui a soma dos resíduos ao quadrado maior do que a de  $g$ .

**Exemplo 1.** Considere a função  $y = f(x)$  dada pela tabela

$x$	-1	0	1	2
$y$	0	-1	0	7

Ajustá-la por um polinômio do 1º grau usando o método dos mínimos quadrados e calcular a soma dos resíduos ao quadrado (erro de truncamento ou resíduo total).

Neste caso,  $f(x) \approx g(x) = a + bx$  e o número de pontos é  $n = 4$ .

Fazendo as somas do sistema normal,

$$\begin{aligned} \sum_{i=1}^4 1 &= 4 & \sum_{i=1}^4 x_i &= -1 + 0 + 1 + 2 = 2 \\ \sum_{i=1}^4 x_i^2 &= (-1)^2 + 0^2 + 1^2 + 2^2 = 6 & \sum_{i=1}^4 f(x_i) &= 0 + (-1) + 0 + 7 = 6 \\ \sum_{i=1}^4 x_i f(x_i) &= (-1)(0) + (0)(-1) + (1)(0) + (2)(7) = 14 \end{aligned}$$


O sistema fica

$$\begin{cases} 4a + 2b = 6 \\ 2a + 6b = 14 \end{cases}$$

que possui a solução  $a = 0.4$  e  $b = 2.2$ .

Portanto, a função de ajuste é  $g(x) = 0.4 + 2.2x$ . Esta é a reta que melhor se ajusta aos pontos da tabela. Sua soma dos resíduos ao quadrado (erro de truncamento) é

$$\begin{aligned} \sum_{i=1}^4 [f(x_i) - 0.4 - 2.2x_i]^2 &= [0 - 0.4 - 2.2(-1)]^2 + [-1 - 0.4 - 2.2(0)]^2 + [0 - 0.4 - 2.2(1)]^2 \\ &+ [7 - 0.4 - 2.2(2)]^2 = 1.8^2 + (-1.4)^2 + (-2.6)^2 + 2.2^2 = 16.8. \end{aligned}$$



## Ajuste linear - caso contínuo

$f$  definida em um intervalo  $[c, d]$  e  $g$  um polinômio do 1º grau, ou seja,

$$f(x) \approx g(x) = a + bx$$

e queremos determinar os parâmetros  $a$  e  $b$  de modo que a função  $g$  esteja mais próxima possível da  $f$  no sentido dos mínimos quadrados.

Neste caso, definimos a forma de medir o erro entre  $f$  e  $g$  por

$$r(x) = f(x) - g(x).$$

Para determinarmos os parâmetros  $a$  e  $b$  de modo que a distância entre  $f$  e  $g$  seja mínima, chamamos  $M(a, b) = \int_c^d (r(x))^2 dx = \int_c^d [f(x) - a - bx]^2 dx$ , derivamos  $M$  parcialmente em relação à  $a$  e parcialmente em relação à  $b$  e igualamos as derivadas a zero

$$\begin{aligned}\frac{\partial M}{\partial a} &= 2 \int_c^d [f(x) - a - bx](-1) dx = 0 \\ \frac{\partial M}{\partial b} &= 2 \int_c^d [f(x) - a - bx](-x) dx = 0\end{aligned}$$

com isso, obtemos o sistema normal

$$\begin{cases} \left( \int_c^d 1 dx \right) a + \left( \int_c^d x dx \right) b = \int_c^d f(x) dx \\ \left( \int_c^d x dx \right) a + \left( \int_c^d x^2 dx \right) b = \int_c^d x f(x) dx \end{cases} \quad (2)$$

cujas soluções correspondem aos parâmetros procurados.

**Exemplo 2.** Seja  $f(x) = x^4 - 5x$ ,  $x \in [-1, 1]$ . Aproximar  $f(x)$  por um polinômio do 1º grau usando o método dos mínimos quadrados.

Começamos pelo cálculo das integrais do sistema normal (2) de  $-1$  a  $1$

$$\int_{-1}^1 1 dx = x \Big|_{-1}^1 = 2$$

$$\int_{-1}^1 x dx = \frac{x^2}{2} \Big|_{-1}^1 = 0$$

$$\int_{-1}^1 x^2 dx = \frac{x^3}{3} \Big|_{-1}^1 = \frac{2}{3}$$


$$\int_{-1}^1 f(x) dx = \int_{-1}^1 (x^4 - 5x) dx = \left( \frac{x^5}{5} - \frac{5x^2}{2} \right) \Big|_{-1}^1 = \frac{2}{5}$$

$$\int_{-1}^1 x f(x) dx = \int_{-1}^1 (x^5 - 5x^2) dx = \left( \frac{x^6}{6} - \frac{5x^3}{3} \right) \Big|_{-1}^1 = -\frac{10}{3}$$

Assim, obtemos

$$\begin{cases} 2a + 0b = \frac{2}{5} \\ 0a + \frac{2}{3}b = -\frac{10}{3} \end{cases}$$

que tem como solução  $a = \frac{1}{5}$  e  $b = -5$ . Portanto,  $g(x) = \frac{1}{5} - 5x$ .



## Exercícios

1) A tabela a seguir mostra um experimento sobre a relação entre pressão e temperatura para um gás ideal em um volume constante

$T(^{\circ}\text{C})$	0	10	20	30	40	50	60	70	80	90	100
$p(\text{atm.})$	0,94	0,96	1,0	1,05	1,07	1,09	1,14	1,17	1,21	1,24	1,28

(a) ajuste os dados por uma reta;

$$p(T) \approx g(T) = a + bT$$

$n = 11$  pontos

caso discreto

calcular os 5 somatórios, montar o sistema normal e resolver. Encontrando  $a$  e  $b$  substitui na função  $g$ .

(b) Extrapolando (estendendo) os dados até que cruze o eixo  $T$  horizontal, obtemos uma estimativa da temperatura do zero absoluto. Determine essa aproximação.

2) Aproximar  $f(x) = e^x$  por uma reta no intervalo  $[0, 1]$  e calcular o erro de truncamento.  
caso contínuo, semelhante ao Exemplo 2.

3) Resolver o sistema (1) pela regra de Cramer.

Regra de Cramer para resolver um sistema linear  $Ax = b$ , onde  $x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$

$x_1 = \frac{\det(A_1)}{\det(A)}$ , onde  $A_1$  é a matriz  $A$  com a coluna 1 substituída pelo vetor  $b$

$x_2 = \frac{\det(A_2)}{\det(A)}$ , onde  $A_2$  é a matriz  $A$  com a coluna 2 substituída pelo vetor  $b$

Escrevendo na forma matricial o sistema normal do caso discreto, temos um sistema

$$\begin{pmatrix} \sum_{i=1}^n 1 & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n f(x_i) \\ \sum_{i=1}^n x_i f(x_i) \end{pmatrix}$$

$$A = \begin{pmatrix} \sum_{i=1}^n 1 & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix}, A_1 = \begin{pmatrix} \sum_{i=1}^n f(x_i) & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i f(x_i) & \sum_{i=1}^n x_i^2 \end{pmatrix} \text{ e } A_2 = \begin{pmatrix} \sum_{i=1}^n 1 & \sum_{i=1}^n f(x_i) \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i f(x_i) \end{pmatrix}$$

$$a = \frac{\det(A_1)}{\det(A)} = \frac{\sum_{i=1}^n f(x_i) \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i f(x_i)}{\sum_{i=1}^n 1 \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i}$$

$$b = \frac{\det(A_2)}{\det(A)} = \frac{\sum_{i=1}^n 1 \sum_{i=1}^n x_i f(x_i) - \sum_{i=1}^n f(x_i) \sum_{i=1}^n x_i}{\sum_{i=1}^n 1 \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i}$$

- 4) Escrever um algoritmo para o ajuste linear discreto usando o resultado do Exercício 3).

Dados de entrada:

n ( inteiro): quantidade de pontos

x[n] (vetor de números reais): valores de  $x$  tabelados

f[n] (vetor de números reais): valores de  $f(x)$  tabelados

Saída: coeficientes a e b da reta  $g(x) = a + bx$

INICIO

somax=0

somax2=0

somaf=0

somaxf=0

Para i de 1 até n faça

    somax=somax+x[i]

    somax2=somax2+x[i]\*x[i]

    somaf=somaf+f[i]

    somaxf=somaxf+x[i]\*f[i]

fim

numa = somaf\*somax2-somax\*somaxf

numb = soman\*somaxf-somaf\*somax

denom = n\*somax2-somax\*somax

a=numa/denom

b=numb/denom

Escreva “A reta de ajuste é  $g(x)=a'+b'x$  .”

FIM

- 5) O coeficiente  $R^2$  é bastante utilizado para medir a qualidade do modelo em relação

à sua habilidade de estimar corretamente os dados. É dado por

$$R^2 = 1 - \frac{SQ_{res}}{SQ_{tot}}$$

onde  $\bar{y} = \frac{1}{n} \sum_{i=1}^n f(x_i)$  (ponto médio),  $SQ_{tot} = \sum_{i=1}^n [g(x_i) - \bar{y}]^2$  (erro total) e

$$SQ_{res} = \sum_{i=1}^n [f(x_i) - \bar{y}]^2 \text{ (erro residual) .}$$

Calcule o coeficiente  $R^2$  do ajuste do Exemplo 1. [Incluir o cálculo do  \$R^2\$  no algoritmo do ajuste linear.](#)